《信息论课程大作业》

算术编码及其应用

班级：1601014

姓名：马秋平

学号：16010140048

一 算法原理

算术编码的主要思想是计算输入信源符号序列所对应的区间，然后在区间中间任取一点，以二进制表示适当截断作为序列的编码结果。

算术编码用到两个基本的参数：符号的概率和它的编码间隔。信源符号的概率决定压缩编码的效率，也决定编码过程中信源符号的间隔，而这些间隔包含在 0 到 1 之间。编码过程中的间隔决定了符号压缩后的输出。

算术编码方法是将被编码的一则消息或符号串（序列）表示成 0 和 1 之间的一个间隔，即对一串符号直接编码成[0,1]区间上的一个浮点小数。符号序列越长，编码表示它的间隔越小，表示这一段间隔所需的位数也就越多。信源中的符号序列任然需要根据某种模式生成概率的大小来减少间隔。可能出现的符号概率要比不太可能出现的符号减少范围小，因此，只正加较少的比特位。

在传输任何符号串之前，0 符号串的完整范围设置为[0,1]。当一个符号被处理时，这一范围就依据分配这一符号的范围变窄。算术编码的过程，实际上就是依据信源符号的发生概率对码区间进行分割的过程。

给定事件序列的算术编码步骤如下：

（1）编码器在开始时将“当前间隔” [L， H) 设置为[0，1)。

（2）对每一事件，编码器按步骤（a）和（b）进行处理

（a）编码器将“当前间隔”分为子间隔，每一个事件一个。

（b）一个子间隔的大小与下一个将出现的事件的概率成比例，编码器选择子间隔对应于下一个确切发生的事件相对应，并使它成为新的“当前间隔”。

（3）最后输出的“当前间隔”的下边界就是该给定事件序列的算术编码。

算术编码的译码过程就是一系列的比较过程，每一步比较$\mathrm{S}-\mathrm{F}(u_i)$与

$P(u_i)F(u_{i+1})$的大小，u_i为前面已经译出的字符串序列，$F(u_i)$是u_i的分布函数，即u_i对应区间的下界，$P(u_i)F(u_{i+1})$是此区间内下一个输入符号u_{i+1}所占区间的宽度，对于 K 元信源，译每一个码元最多需要 K-1 次比较以确定u_{i+1}是信源符号集中的哪一个。

二 算法流程框图

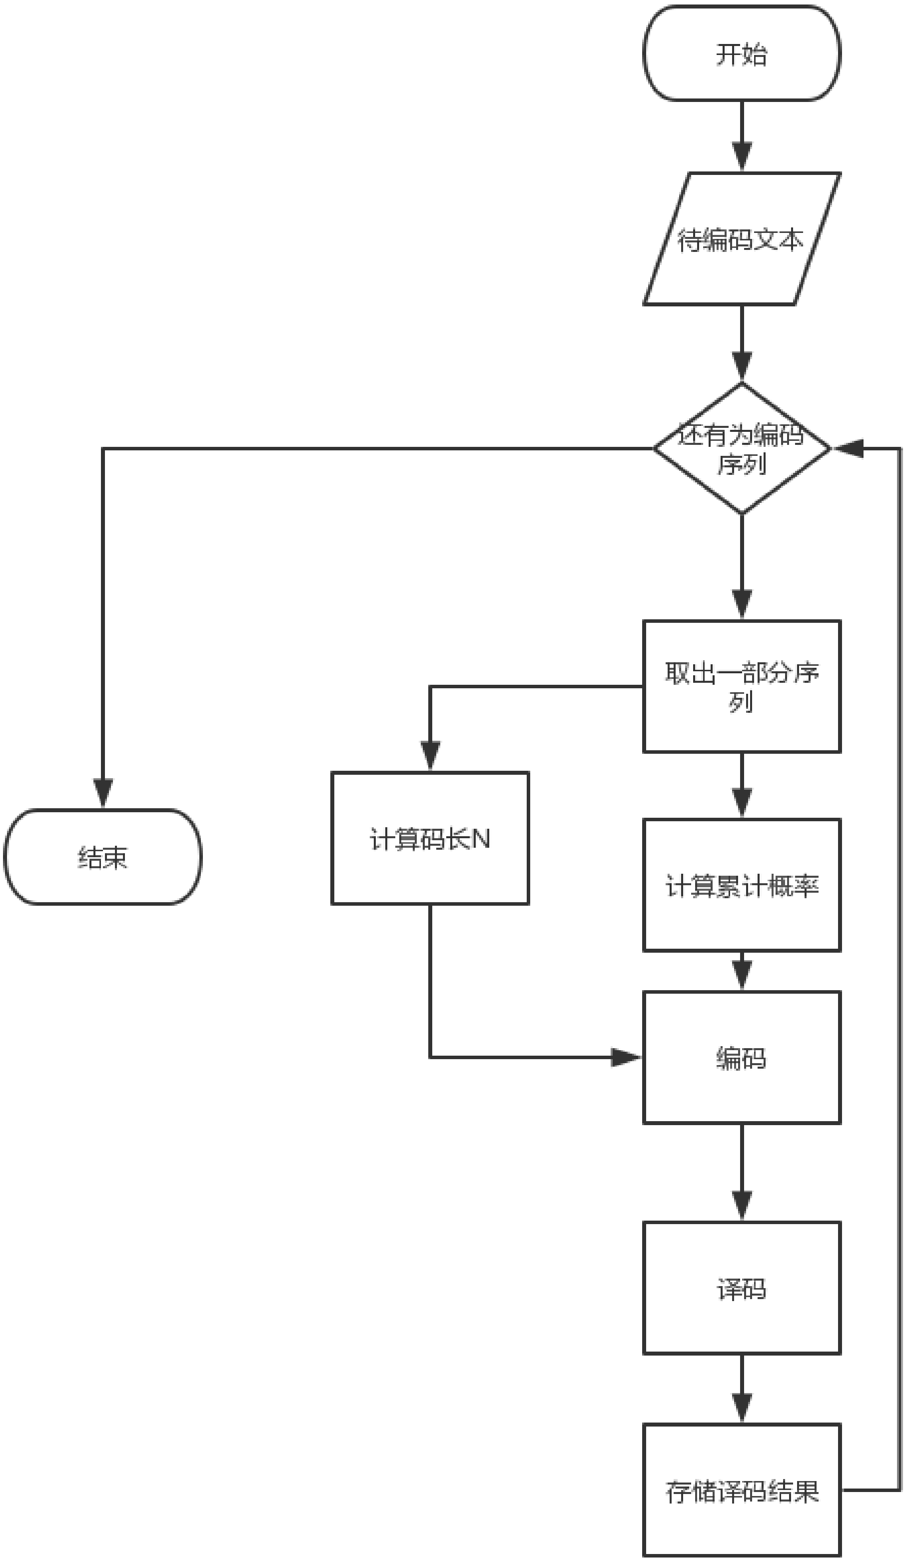

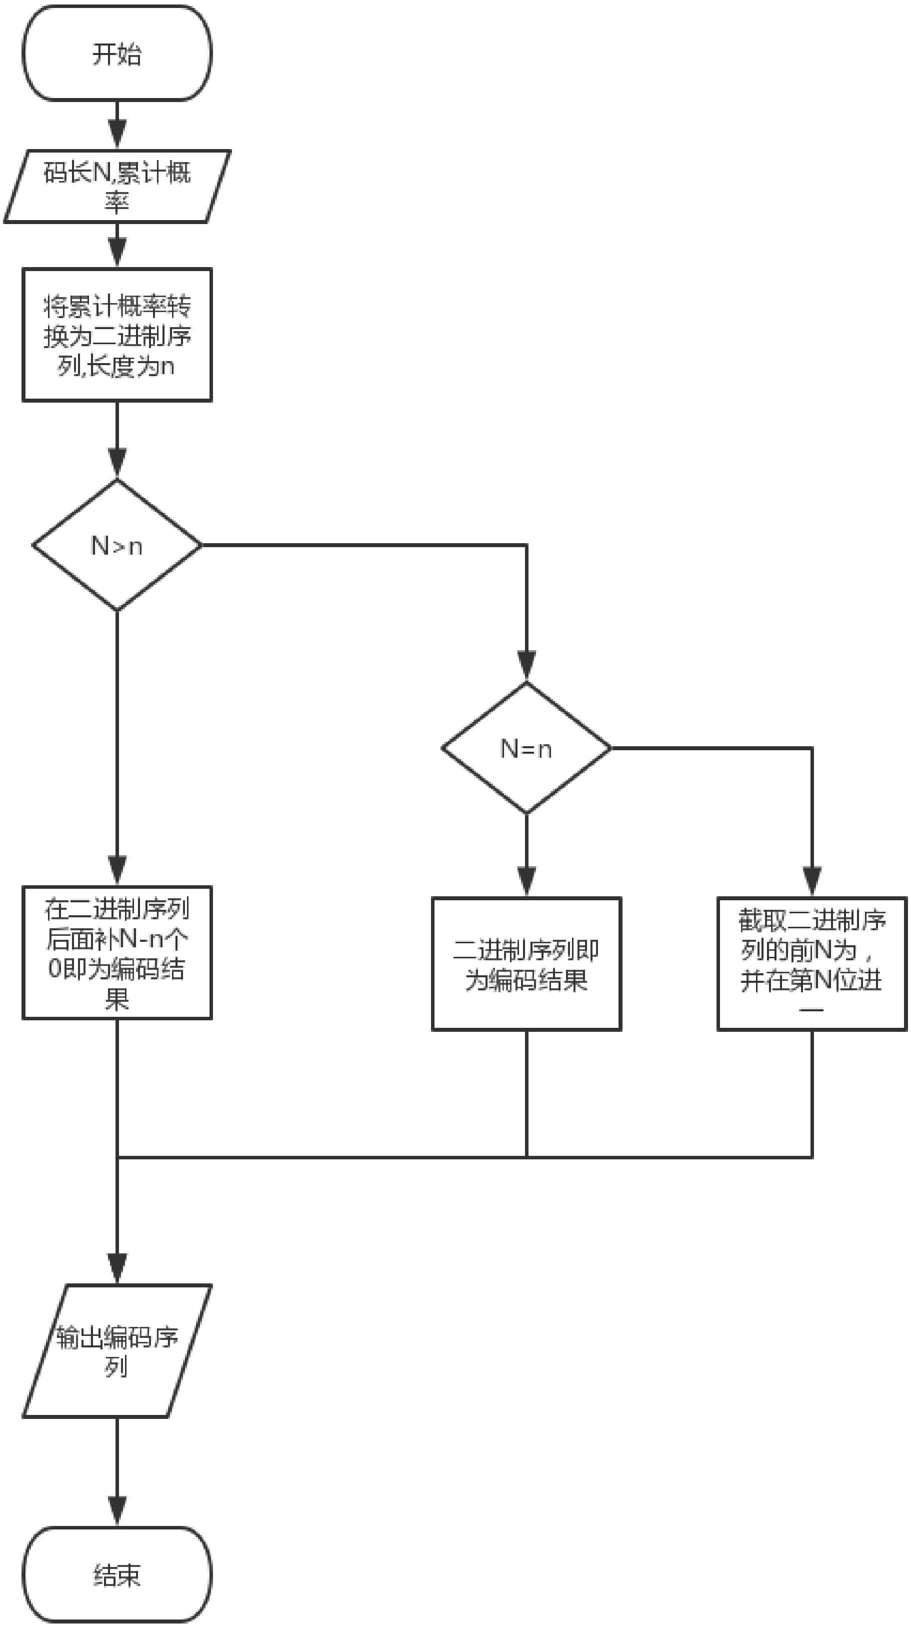
开始
码长N,累计概率
将累计概率转换为二进制序列,长度为n
N>n
N=n
在二进制序列后面补N-n个0即为编码结果
二进制序列即为编码结果
截取二进制序列的前N为，并在第N位进一
输出编码序列
结束

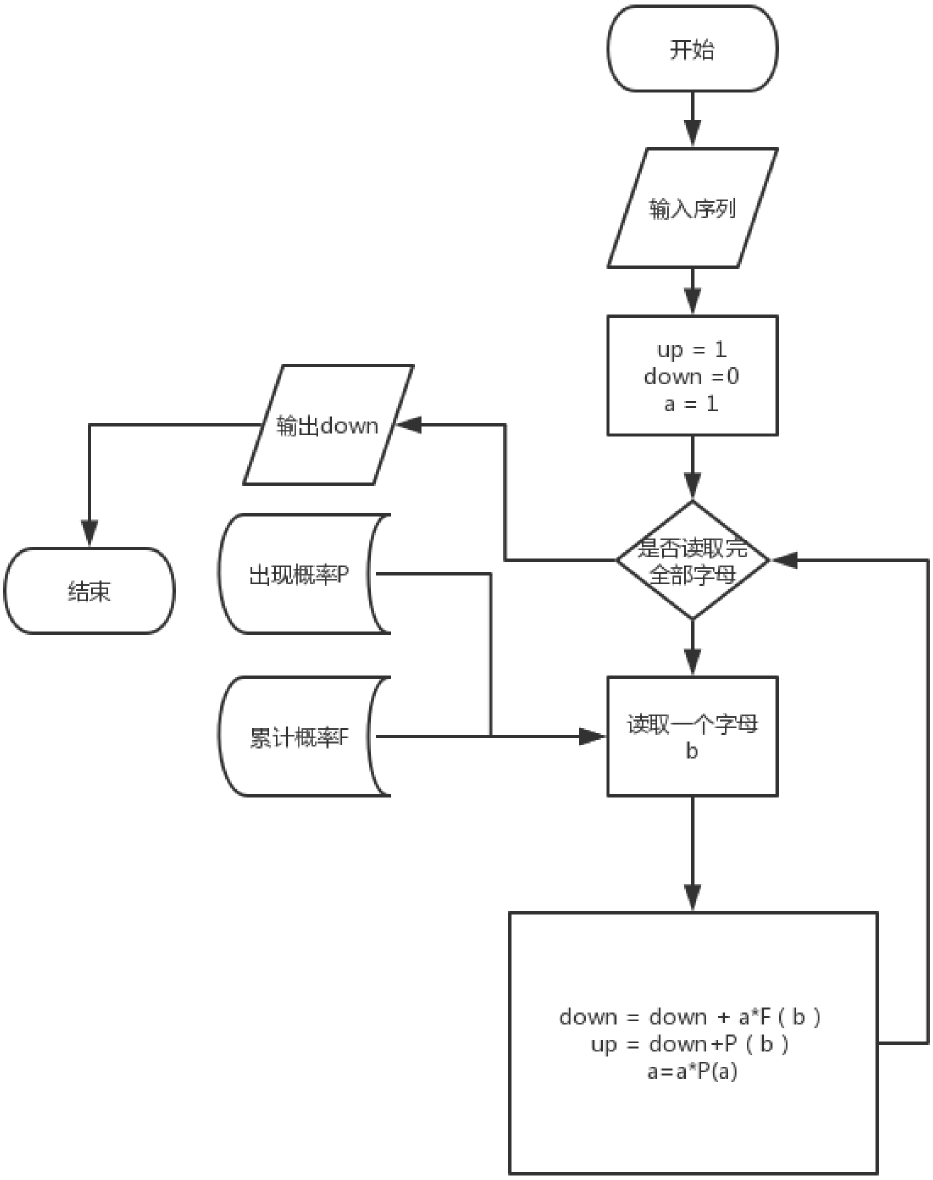

开始
输入序列
up = 1
down =0
a = 1
是否读取完全部字母
输出down
结束
出现概率P
累计概率F
读取一个字母b
down = down + a*F (b)
up = down+P (b)
a=a*P(a)

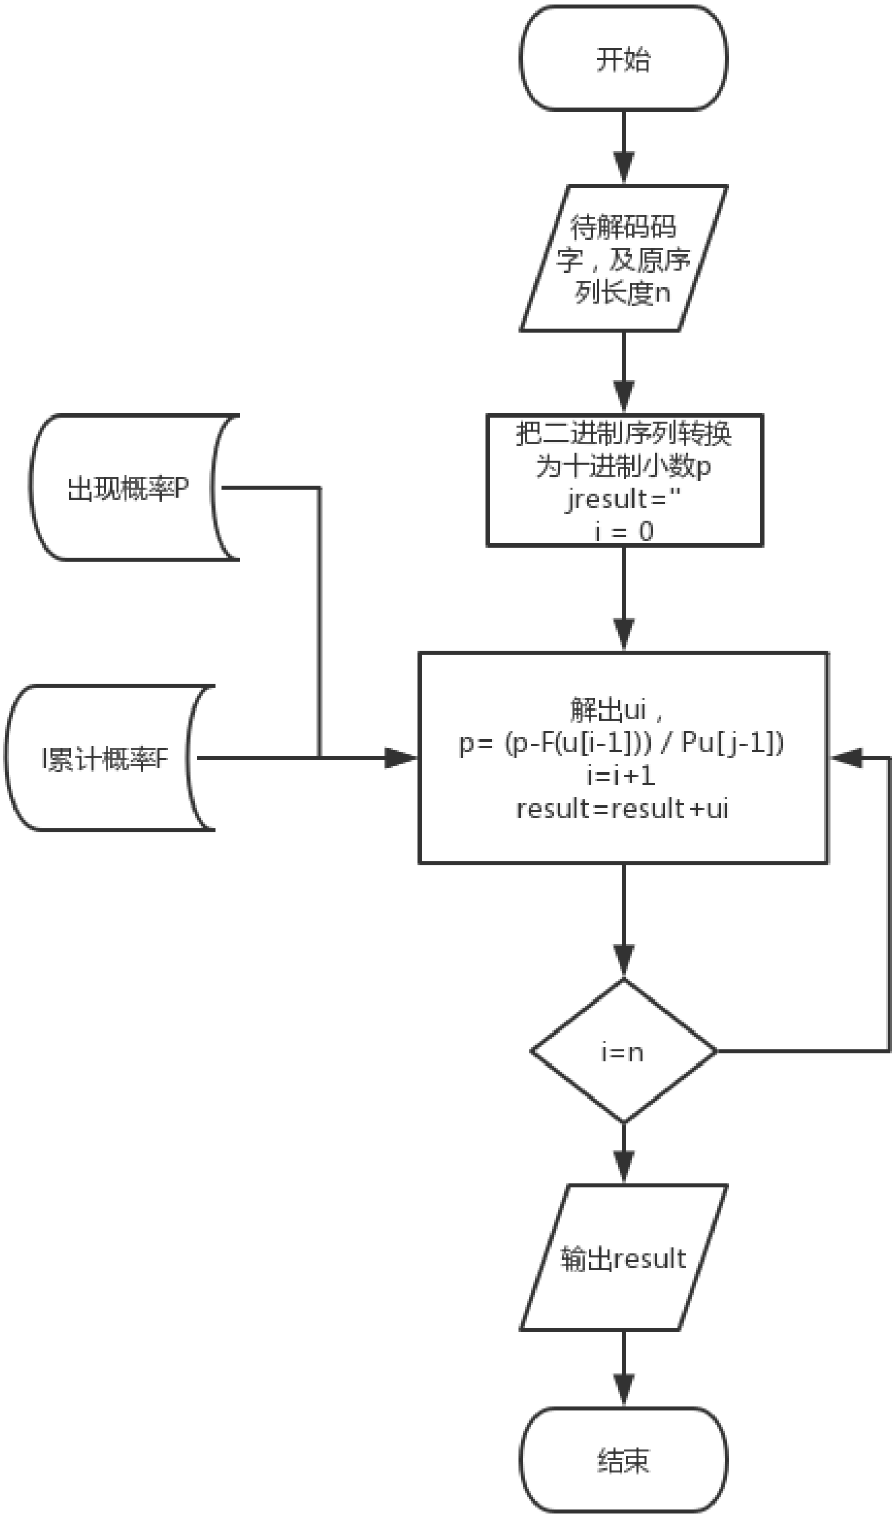

开始
待解码码字，及原序列长度n
把二进制序列转换为十进制小数p
jresult=''
i = 0
出现概率P
l累计概率F
解出ui，
p= (p-F(u[i-1])) / Pu[j-1])
i=i+1
result=result+ui
i=n
输出result
结束

三 实验过程

1. 测试文档（test.txt）

   Financial regulators in Britain have imposed a rather unusual rule on the bosses of big banks. Starting next year, any guaranteed bonus of top executives could be delayed 10 years if their banks are under investigation for wrongdoing. The main purpose of this “clawback” rule is to hold bankers accountable for harmful risk-taking and to restore public trust in financial institutions. Yet officials also hope for a much larger benefit: more long-term decision making, not only by banks but by all corporations, to build a stronger economy for future generations.

2. 实验代码（Python 实现）

```
# -*-coding:utf-8-*-
import time
import numpy as np
import pprint
import matplotlib.pyplot as plt
import random

alpha_dict = {
    'a': 0.0575,
    'b': 0.0128,
    'c': 0.0263,
    'd': 0.0285,
    'e': 0.0913,
    'f': 0.0173,
    'g': 0.0133,
    'h': 0.0313,
    'i': 0.0599,
    'j': 0.0006,
    'k': 0.0084,
    'l': 0.0335,
    'm': 0.0235,
    'n': 0.0596,
    'o': 0.0689,
    'p': 0.0192,
    'q': 0.0008,
    'r': 0.0508,
    's': 0.0567,
    't': 0.0706,
    'u': 0.0334,
    'v': 0.0069,
    'w': 0.0119,
    'x': 0.0073,
    'y': 0.0164,
```

```
    'z': 0.0007,
    ' ': 0.1928,
}


color = ['#dc2624', '#2b4750', '#45a0a2',
         '#e87a59', '#7dcaa9', '#649E7D',
         '#dc8018', '#C89F91', '#6c6d6c',
         '#4f6268', '#c7cccf'
         ]


# 计算信源熵
def calc_entropy(alpha_dict):
    entropy = 0
    gailv_jihe = list(alpha_dict.values())
    for i in range(len(alpha_dict)):
        entropy = entropy+gailv_jihe[i]*np.log(gailv_jihe[i])
    return -entropy


# 计算累乘概率
def mul_pos(input_str=''):
    pre_possibility = 1
    input_list = list(input_str)
    for i in input_list:
        pre_possibility = pre_possibility*alpha_dict.get(i)

    return pre_possibility


# 计算码长
def calc_machang(leic_possibility):
    ma_length = np.ceil(-np.log(leic_possibility)/np.log(2))
    return ma_length


# 十进制小数转换为二进制小数
def dec2bin(x):
    x -= int(x)
    bins = []
    while x:
        x *= 2
        bins.append(1 if x >= 1. else 0)
```

```python
        x -= int(x)
    return bins


# 二进制小数转换为十进制小数
def bin2dec(b):
    d = 0
    for i, x in enumerate(b):
        d += 2**(-i-1)*x
    return d


# 二进制小数进位
def bin_jinwei(input_bin=[]):
    for i in range(len(input_bin)):
        if input_bin[len(input_bin) - 1 - i] == 0:
            input_bin[len(input_bin) - 1 - i] = 1
            break
        else:
            input_bin[len(input_bin) - i - 1] = 0
    return input_bin


def accu_pos(para_dict):
    accu_pos_dict = {}
    # print(len(alpha_dict))
    for i in range(len(para_dict)):
        pre_pos = 0
        pre_alpha = list(para_dict.keys())[i]
        if i == 0:
            pre_pos = 0
        else:
            for j in range(i):
                pre_pos = list(para_dict.values())[j]+pre_pos
        accu_pos_dict[pre_alpha] = pre_pos

    return accu_pos_dict


# 计算待编码序列的累计概率
def calc_xulie_pos(xulie, accu_pos_dict={}):
    xulie = list(xulie)
    alpha_list = list(alpha_dict.keys())
    pos_down = 0
```

```
    pos_up = 0
    accu = 1
    plt.ion()
    xianshi = ''
    for i in range(len(xulie)):
        xianshi = xianshi+xulie[i]
        pos_down = pos_down + accu*accu_dict.get(xulie[i])
        pos_up = pos_down + alpha_dict.get(xulie[i])*accu
        accu = accu * alpha_dict.get(xulie[i])
        # plt.xlim(accu_dict[xulie[0]], accu_dict[xulie[0]]+alpha_dict[xulie[0]])
        plt.ylim(0, 10)
        plt.axvspan(pos_down, pos_up, 0, 0.2, alpha=(1-i*0.1), color=random.sample(color, 1)[0])
        plt.axvline(pos_down, 0, 0.3, color=random.sample(color, 1)[0])
        plt.text(pos_down, 5, 'P({})={}'.format(xianshi, pos_down))
        plt.show()
        time.sleep(1)
    plt.ioff()
    plt.close()
    # leiji_pos = (pos_down + pos_up) / 2
    leiji_pos = pos_down

    return leiji_pos


## 解码过程
def decode_proceing(rec_pos, accu_pos_dict, machang=0):
    pre_pos = rec_pos
    alpha_list = list(alpha_dict.keys())
    # print(alpha_list)
    jiema_result = ''
    for i in range(machang):
        for j in range(1, len(alpha_list)):
            leijigailv = accu_pos_dict.get(alpha_list[j])
            if pre_pos > 0.8074:
                jiema_result = jiema_result+' '
                pre_pos = (pre_pos - accu_dict.get(' ')) / alpha_dict.get(' ')
                break
            elif pre_pos < leijigailv:
                jiema_result = jiema_result+alpha_list[j-1]
                pre_pos = (pre_pos-accu_dict.get(alpha_list[j-1])) / alpha_dict.get(alpha_list[j-1])
                break

    return jiema_result
```

```python
# 将累计概率由十进制小数转换为二进制小数
def pos_change(leijigailv):
    bin_pos = dec2bin(leijigailv)
    return bin_pos


# 从小数后截取 N 位，如果后还有尾数则进位，如果不足则补零
def bianma(bin_pos, pre_length=30):
    pre_result = []
    if len(bin_pos) == pre_length:
        pre_result = bin_pos
    elif len(bin_pos) >= pre_length:
        '''
        如果 N 小于二进制概率位数，则将二进制小数的第 N 位进 1，然后截取 N 位
        '''
        pre_result = bin_pos[:pre_length]
        pre_result = bin_jinwei(pre_result)

    else:
        '''
        如果 N 大于二进制概率位数，则将二进制小数位后面补零至 N 位，然后截取 N 位
        '''
        for i in range(pre_length-len(bin_pos)):
            bin_pos.append(0)
            pre_result = bin_pos
    return pre_result


if __name__ == "__main__":
    resouse_entropy = calc_entropy(alpha_dict)
    print("信源熵为：{}".format(resouse_entropy))
    accu_dict = accu_pos(alpha_dict)
    pprint.pprint(accu_dict)
    f_test = open('test.txt', 'r')
    text = f_test.read()
    a = ''
    count = 0
    with open('result.txt', 'a') as f:
        for i in range(len(text)):
            alp = text[i].lower()
            if alp in alpha_dict.keys():
                a += alp
                if alp == ' ':
```

```
                print(a)
                r = calc_xulie_pos(a, accu_pos_dict=accu_dict)
                lei_possibility = mul_pos(a)
                N = calc_machang(leic_possibility=lei_possibility)
                print(N)
                print(r)
                bin_pos = pos_change(r)
                bin_pos = bianma(bin_pos=bin_pos, pre_length=int(N))
                print(bin_pos)
                back_pos = bin2dec(bin_pos)
                print(back_pos)
                result = decode_proceing(back_pos, accu_pos_dict=accu_dict, machang=len(a))
                print(result)
                count += 1
                f.write(result)
                if count == 12:
                    f.write('\n')
                    count = 0
                a = ''
            else:
                a += ' '

    f_test.close()
```

四 实验结果及分析

译码后的文档：（result.txt）

financial regulators in britain have imposed a rather unusual rule on the
bosses of big banks starting next year any guaranteed bonus of top
executives could be delayed   years if their banks are under investigatin
m
for wrongdoing the main purpose of this clawback yrule is to hold
bankers accountable for harmful risk takingsand to restore public trust in
financial
institutiontabyet officials also hope for a much larger benefit more long
term
decision making not only by banks but by all corporationtaato build
a stronger economy for future

分析：

1. 由于所给信源符号集中只有小写字母及空格，所以在编码过程中我将大写转换为小写，将除空格外的符号全部转换为空格。
2. 由于 Python 的浮点数精度只有小数点后 17 位，所以每次编码的序列长度不能过长，当字符串序列长度过长时，序列区间越来越小，计算机不能精确识别，导致译码错误，由于我是以空格来作为字符串的结束标志，所以每次

长度不一样，比如原文中的“investigation”错误的译成了“investigatin m”。

3. 由于 ASCII 码在计算机中占 7 个二进制位，所以我们可以用编码后的二进制码长度和序列长度与 7 的乘积来计算编码效率。

运行结果如下：

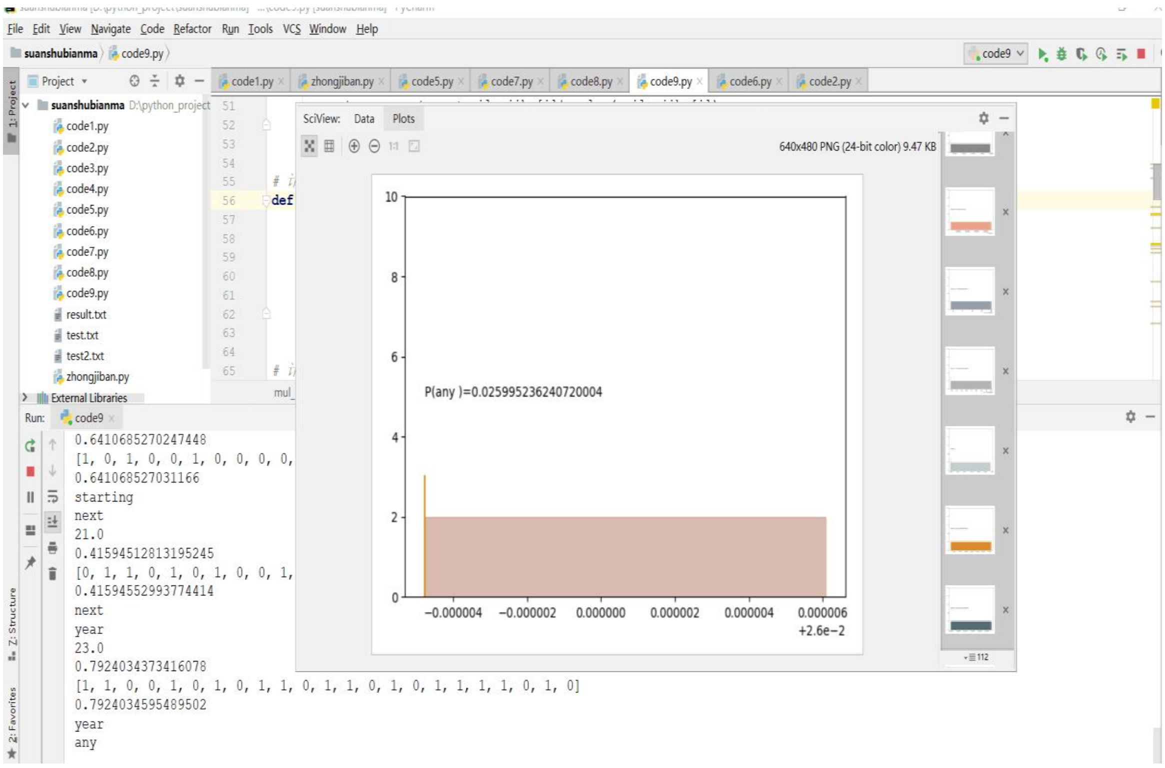

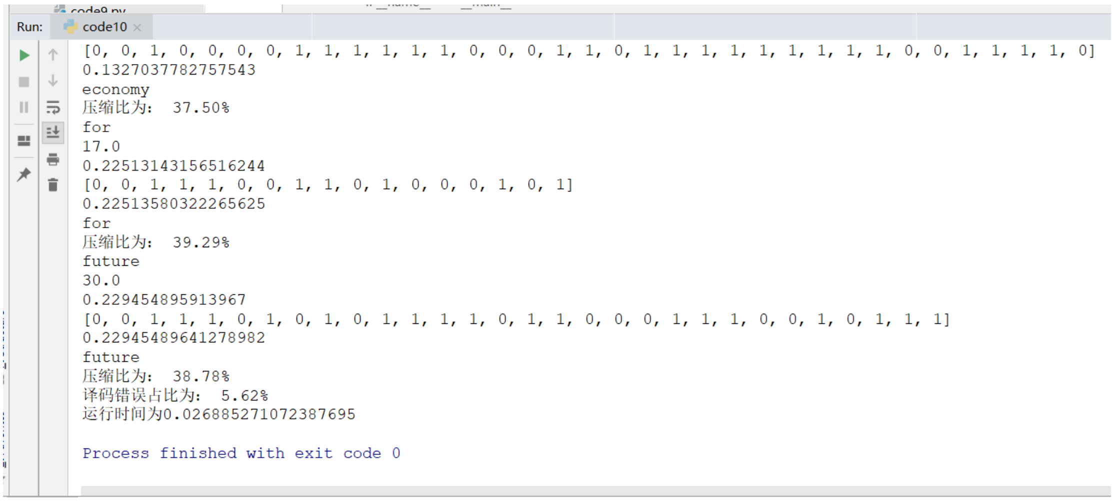

```
[0, 0, 1, 0, 0, 0, 0, 1, 1, 1, 1, 1, 1, 0, 0, 0, 1, 1, 0, 1, 1, 1, 1, 1, 1, 1, 1, 1, 0, 0, 1, 1, 1, 1, 0]
0.1327037782757543
economy
压缩比为:  37.50%
for
17.0
0.22513143156516244
[0, 0, 1, 1, 1, 0, 0, 1, 1, 0, 1, 0, 0, 0, 1, 0, 1]
0.22513580322265625
for
压缩比为:  39.29%
future
30.0
0.229454895913967
[0, 0, 1, 1, 1, 0, 1, 0, 1, 0, 1, 1, 1, 1, 0, 1, 1, 0, 0, 0, 1, 1, 1, 0, 0, 1, 0, 1, 1, 1]
0.22945489641278982
future
压缩比为:  38.78%
译码错误占比为:  5.62%
运行时间为0.026885271072387695

Process finished with exit code 0
```

五 心得与体会